LISTEN: когда робот начинает слушать инструкцию?

Идея исследования и текущий статус

nonberw

3 ноября 2026 г. (статус обновлён после экспериментов)

Коротко. Роботы, которыми управляют словами (VLA-модели), часто *не читают* инструкцию и делают то, что привыкли делать в знакомой сцене. Все считают, что виноваты данные: каждая сцена в датасетах показана почти всегда с одной задачей. Но **никто не проверил это экспериментом**. Мы проверяем: обучаем одинаковых роботов на одинаковом объёме данных и меняем только долю *контрастных* сцен (одна сцена — разные инструкции). Вопрос: сколько таких сцен нужно, чтобы робот начал слушать *везде*.

1 Проблема

Мечта современной робототехники — универсальный робот, которому говоришь словами: «возьми красную чашку». Такие модели называются VLA (vision–language–action): смотрят камерой, читают текст, двигают рукой. В 2025–2026 годах несколько групп показали, что они часто *игнорируют* текст: если поменять инструкцию, но оставить сцену, робот выполняет привычную для этой сцены задачу, а иногда работает почти так же хорошо с пустой инструкцией.

Работа	Что показала
LIBERO-Plus [2]	Модели почти не реагируют на изменения инструкции; при подмене цели продолжают делать старую задачу.
LIBERO-PRO [7]	Высокие баллы на LIBERO во многом объясняются запоминанием, а не пониманием.
LIBERO-CF [1]	«Зрение перебивает язык»: при контрфактических инструкциях модели делают выученную в сцене задачу. Предлагают исправление на этапе запуска.
Encoded but Not in Control [4]	Нужная цель *закодирована* внутри модели, но не управляет действием.
Mechanistic study [5]	Где внутри модели теряется влияние языка (activation patching).

Таблица 1: Что уже известно. Все эти работы *наблюдают* проблему на готовых больших моделях.

2 Пробел: почему это происходит?

Общее объяснение — **структура данных**. В датасетах для роботов каждая сцена показана с одной–двумя задачами, поэтому по картинке и так понятно, что делать, и читать текст модели «невыгодно». Это похоже на ученика, который запомнил, что на странице 42 ответ всегда «15», и перестал читать условие.

Но у больших моделей нельзя поменять обучающие данные, поэтому все работы только *предполагают* причину. Авторы [4] прямо пишут, что не устанавливают причинный механизм, и называют работой на будущее обучение, где инструкция должна выбирать между разными задачами в одной сцене. Ровно это мы и делаем.

Параллель из другой области. В задаче вопросов по картинкам (VQA) модели отвечали, не глядя на картинку. Это лечили *парами*: одна и та же формулировка вопроса, разные картинки и ответы [3]. Наши контрастные сцены — аналог этого для роботов, только с переставленными ролями: одна картинка, разные инструкции.

3 Наш вопрос и гипотезы

Вопрос: при фиксированном объёме данных как доля контрастных сцен f влияет на то, следует ли робот инструкции?

- **H1.** Без контрастных сцен ($f = 0$) робот в незнакомой для сцены просьбе почти не слушается и берёт «привычный» блок.
- **H2.** Чем больше f, тем лучше робот слушается.
- **H3 (главная).** Контраст *в одних* сценах учит слушать *в других*, где контраста не было: «слушание» обобщается.
- **H4.** Это не ухудшает умение брать блок.

Гипотезы, метрики и план анализа записаны и **закоммичены в git до первого эксперимента** (пререгистрация). Это защита от подгонки выводов под результат.

4 Дизайн эксперимента

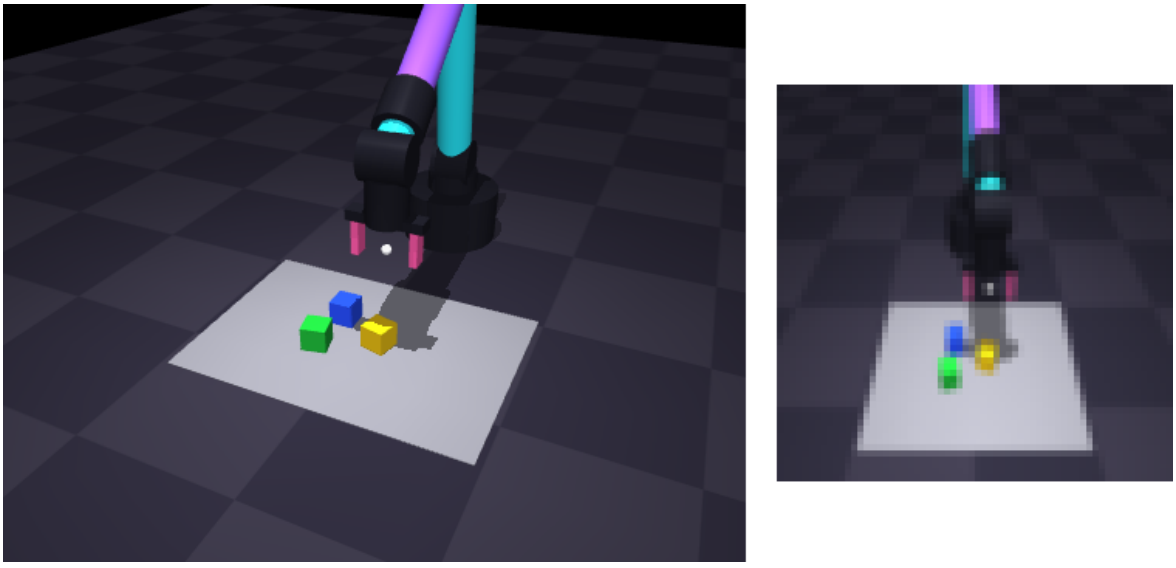


Рис. 1: Слева — сцена: рука (из проекта ARMageddon) и три цветных блока. Справа — всё, что видит робот: картинка 64×64. Плюс инструкция вида «grab the blue block».

- **40 сцен**, в каждой 3 блока из 4 цветов на своих местах (с небольшим случайным сдвигом).

- **Обычная сцена** показана всегда с одной целью (30 демонстраций). **Контрастная** — со всеми тремя целями (по 10). Цели обычных сцен сбалансированы по цветам, чтобы правило «всегда бери красный» не работало.
- **6 условий**: $f = 0,\ 0.05,\ 0.1,\ 0.25,\ 0.5,\ 1$. В каждом **ровно 1200 демонстраций**.
- **Модель**: свёрточная сеть + язык через FiLM от замороженного энкодера MiniLM, предсказание пачки из 5 действий (как в ACT [6]). Рецепт обучения одинаковый везде.
- **Проверка**: в сценах 20–39 (обычных во всех условиях до $f = 0.5$) просим блок, который в этой сцене *ни разу* не просили. Смотрим, на каком блоке робот сомкнёт пальцы.
- **3 сида** на условие, 660 эпизодов проверки на каждую обученную политику, бутстреп-интервалы и логистическая регрессия.

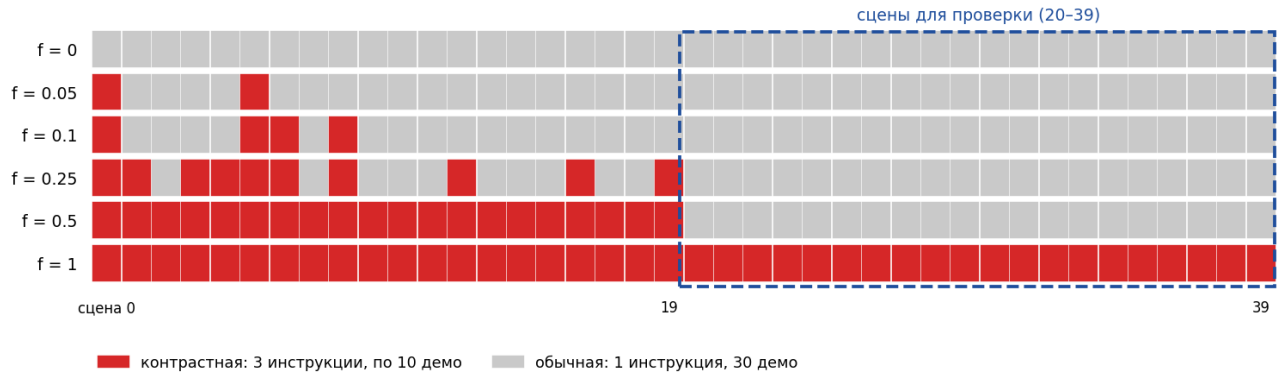


Рис. 2: Какие сцены контрастные в каждом условии. Наборы вложены друг в друга, а сцены 20–39 используются для проверки.

5 Что уже есть

Поиск литературы и проверка новизны	**готово**
Пререгистрация (git, до экспериментов)	**готово**
Сцена, скриптовый эксперт (30/30 успешно), пул из 3600 демонстраций	**готово**
Модель, обучение, оценка, 15 тестов дизайна	**готово**
Пилот (2 политики)	**готово**
Основной эксперимент: 18 обучений	**готово**
Эксперимент E (4 сцены вместо 40)	**готово**
Статистика, графики, статья в LaTeX, репозиторий на GitHub	**готово**

Пилот: первая проблема и первая неожиданность

Сначала робот доезжал до блока с точностью 2 мм, но *никогда не сжимал пальцы*. Моменты «доехал» и «начинаю сжимать» для камеры выглядят одинаково, и сеть застревала посередине. Лечится temporal ensembling (усреднением будущих предсказаний, как в ACT). Это изменение разрешено пререгистрацией на этапе пилота и задокументировано.

Наше объяснение: в этом дизайне связать слово «red» с красным цветом *проще*, чем запомнить нужный блок в каждой из 40 сцен, поэтому коротким путём становится сам язык. Если это так, то «глухота» к языку зависит от того, *что сети легче выучить* — сцену или слово. Для

Пилот (отдельный сид)	берёт названный блок	берёт «привычный»	не берёт ничего	обычная задача
$f = 0$ (контраста нет)	57%	3%	40%	86%
$f = 1$ (всё контрастное)	88%	0%	12%	82%

Таблица 2: Пилот. Неожиданность: без контраста робот почти *не* берёт «привычный» блок, а либо слушается, либо теряется. В статистику гипотез пилот не входит.

проверки добавлен **эксперимент E**: всего 4 сцены (как в LIBERO, где сцен мало), где запомнить сцену легко. Он записан в пререгистрацию *до* результатов основного эксперимента и помечен как разведочный.

Попутная находка: энкодер сам «глуховат»

Готовый языковой энкодер MiniLM считает «pick up the red block» ближе к «pick up the blue block», чем к «grab the red cube». В его векторе **цвет объясняет лишь 32% разброса, а формулировка фразы — 66%**. То есть заметная часть «глухоты» может начинаться ещё до робота, в самом представлении текста.

6 Почему это важно

- **Наука**: первая *причинная* проверка того, почему VLA не слушают язык.
- **Практика**: сбор данных для роботов — самая дорогая часть. Ответ «добавь X% контрастных демонстраций» — прямой рецепт для лабораторий и компаний.
- **Любой исход полезен**: если слушание обобщается, это рецепт; если нет, это важное ограничение, которое надо знать.

7 Итоги (кратко)

Полные результаты — в статье `paper/main.pdf`. Коротко: контраст в части сцен учит робота слушать и в остальных (48,9% $\to$ 61,3% при $f = 0{,}25$, $p = 0{,}033$; 71,3% при $f = 0{,}5$, $p < 10^{-4}$); маленькие дозы (2–4 сцены) не помогают; без контраста робот не «упрямится», а колеблется между названным и привычным блоком; при 4 сценах слушание исчезает полностью (0%), а «привычный» блок возвращается (17%).

8 Что дальше

1. Досчитать основной эксперимент (около 2 часов) и эксперимент E (около часа).
2. Статистика по пререгистрированному плану, графики «доза–эффект».
3. Статья в формате arXiv (на английском) и открытый репозиторий: код, пререгистрация с историей коммитов, записи каждого эпизода.

Список литературы

[1] Yu Fang, Yuchun Feng, Dong Jing, Jiaqi Liu, Yue Yang, Zhenyu Wei, Daniel Szafir, and Mingyu Ding. When vision overrides language: Evaluating and mitigating counterfactual failures in VLAs. *arXiv preprint arXiv:2602.17659*, 2026.

[2] Senyu Fei, Siyin Wang, Junhao Shi, Zihao Dai, Jikun Cai, Pengfang Qian, Li Ji, Xinzhe He, Shiduo Zhang, Zhaoye Fei, Jinlan Fu, Jingjing Gong, and Xipeng Qiu. LIBERO-Plus: In-depth robustness analysis of vision-language-action models. *arXiv preprint arXiv:2510.13626*, 2025.

[3] Yash Goyal, Tejas Khot, Douglas Summers-Stay, Dhruv Batra, and Devi Parikh. Making the V in VQA matter: Elevating the role of image understanding in visual question answering. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2017.

[4] Shaohan Jiang, Jiahang Cao, Qiduo He, Fengting Deng, Kun Wu, Jingkai Sun, Jiaxu Wang, Qiang Zhang, Qihao Zheng, Chunfeng Song, Ping Luo, and Andrew F. Luo. Encoded but not in control: Revealing the grounding gap in vision-language robot policies. *arXiv preprint arXiv:2610.06235*, 2026.

[5] Theodor Wulff and Angelo Cangelosi. Do vision-language-action models understand instructions? A mechanistic interpretability study on language grounding. *arXiv preprint arXiv:2610.10178*, 2026.

[6] Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Robotics: Science and Systems*, 2023.

[7] Xueyang Zhou, Yangming Xu, Guiyao Tie, Yongchao Chen, Guowen Zhang, Duanfeng Chu, Pan Zhou, and Lichao Sun. LIBERO-PRO: Towards robust and fair evaluation of vision-language-action models beyond memorization. *arXiv preprint arXiv:2510.03827*, 2025.